

Redes Neuronales y Aprendizaje Profundo / Taller #2

Curso de Deep Learning – Universidad EAFIT

Preguntas teóricas

1. En una red generativa adversaria (GAN), el generador G_θ tiene como objetivo producir muestras sintéticas que imiten los datos reales. Para ello, recibe como entrada un vector aleatorio

$$z \in \mathbb{R}^n,$$

denominado vector latente. Este vector no representa directamente una imagen ni una observación del conjunto de datos; funciona como una fuente de variabilidad a partir de la cual el generador construye nuevas muestras. Suponga que el vector latente sigue una distribución normal multivariada estándar

$$z \sim \mathcal{N}(0, I_n),$$

donde I_n es la matriz identidad de dimensión n . El generador, parametrizado por θ , transforma este vector en una muestra sintética $x = G_\theta(z)$.

Aunque G_θ es una función determinista, es decir, para un mismo z siempre produce la misma salida, la variable z cambia aleatoriamente en cada muestreo. Como consecuencia, la salida x también es una variable aleatoria cuya distribución se denota por $p_G(x)$.

A partir de esta construcción, responder:

- a. Explique por qué $x = G_\theta(z)$ es una variable aleatoria, aunque G_θ sea una función determinista. En su respuesta, diferencie claramente entre la aleatoriedad de la entrada z y el carácter determinista de la transformación G_θ .
- b. Suponga ahora que se conoce un valor específico del vector latente z . Como el generador es determinista, la salida queda completamente determinada por $x = G_\theta(z)$. Expresé la distribución condicional $p_G(x | z)$ utilizando una delta de Dirac centrada en $G_\theta(z)$. Explique brevemente qué representa esta distribución.
- c. La distribución generada $p_G(x)$ debe considerar todos los posibles vectores latentes z , ponderados de acuerdo con su densidad $p_z(z)$. Utilizando la ley de la probabilidad total,

$$p_G(x) = \int p_G(x | z) p_z(z) dz,$$

y la expresión obtenida en el apartado anterior, demuestre que

$$p_G(x) = \int_{\mathbb{R}^n} \delta(x - G_\theta(z)) p_z(z) dz.$$

Interprete esta expresión como la distribución inducida por G_θ al transformar muestras provenientes del espacio latente.

- d. Considere el caso particular en el que el generador es una función invertible y tanto el espacio latente como el espacio de datos tienen la misma dimensión:

$$z, x \in \mathbb{R}^n.$$

Esto permite recuperar el vector latente asociado a una observación mediante $z = G_{\theta}^{-1}(x)$. Utilizando el teorema de cambio de variables para densidades de probabilidad, demuestre que

$$p_G(x) = p_z\left(G_\theta^{-1}(x)\right) \left|\det J_{G_\theta^{-1}}(x)\right|,$$

- e. donde $J_{G_\theta^{-1}}(x)$ es la matriz jacobiana de la transformación inversa. Explique qué papel desempeña el determinante del jacobiano en la conservación de la probabilidad.
 - f. Analice qué dificultad aparece si la dimensión del espacio latente es menor que la dimensión de los datos.
2. En un modelo GAN, el discriminador recibe una muestra x y trata de determinar su procedencia. La muestra puede provenir de una de estas dos fuentes:

Los datos reales: cuya densidad es $p_{\text{data}}(x)$.

El generador: cuya densidad inducida es $p_G(x)$.

Definimos una variable aleatoria binaria Y que identifica el origen de la muestra:

$$Y = \begin{cases} 1, & \text{si la muestra es real,} \\ 0, & \text{si la muestra fue producida por el generador.} \end{cases}$$

Inicialmente, suponga que ambas fuentes tienen la misma probabilidad de ser seleccionadas, es decir:

$$P(Y = 1) = \frac{1}{2}, P(Y = 0) = \frac{1}{2}.$$

El procedimiento de muestreo puede describirse de la siguiente manera: Se selecciona primero una clase Y . Si $Y = 1$, se extrae X de p_{data} ; Si $Y = 0$, se extrae X de p_G . Por tanto,

$$p(x \mid Y = 1) = p_{\text{data}}(x)$$

y

$$p(x \mid Y = 0) = p_G(x).$$

La densidad marginal de X es entonces la mezcla

$$p(x) = \frac{1}{2}p_{\text{data}}(x) + \frac{1}{2}p_G(x).$$

A partir de esta construcción:

- a. Utilice el teorema de Bayes para calcular

$$P(Y = 1 \mid X = x).$$

- b. Demuestre que, para un generador fijo, el discriminador óptimo es

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}.$$

- c. Generalice el resultado cuando las probabilidades de seleccionar datos reales y generados no sean iguales, sino que

$$P(Y = 1) = \pi, P(Y = 0) = 1 - \pi,$$

con $0 < \pi < 1$.

- d. Explique por qué $D(x) = 0.5$ no significa que una muestra individual sea “mitad real y mitad falsa”, sino que representa incertidumbre sobre su procedencia bajo el modelo probabilístico asumido.
3. En un modelo GAN, el discriminador $D_\phi(x)$ produce un valor entre cero y uno, es decir, $D_\phi(x) \in (0, 1)$. Este valor se interpreta como la probabilidad estimada de que la muestra x provenga de los datos reales. El generador G_θ transforma un vector latente $z \sim p_z(z)$ en una muestra sintética $x_g = G_\theta(z)$. Cuando esta muestra se introduce en el discriminador, se obtiene $D_\phi(G_\theta(z))$. En la formulación **minimax** original de las GAN, el generador minimiza

$$\mathcal{L}_G^{\text{MM}} = \mathbb{E}_{z \sim p_z} [\log(1 - D_\phi(G_\theta(z)))].$$

Esta función le pide al generador reducir la capacidad del discriminador para identificar sus muestras como falsas. Sin embargo, al comienzo del entrenamiento, el discriminador suele reconocer fácilmente las muestras generadas. En consecuencia, $D_\phi(G_\theta(z)) \approx 0$. En esta región, la pérdida **minimax** puede producir gradientes débiles. Por esta razón, en la práctica suele utilizarse la pérdida no saturada

$$\mathcal{L}_G^{\text{NS}} = -\mathbb{E}_{z \sim p_z} [\log D_\phi (G_\theta(z))].$$

Para estudiar el comportamiento de los gradientes, suponga que la salida del discriminador se obtiene aplicando una función sigmoide a un logit a : $D_\phi(G_\theta(z)) = \sigma(a)$, donde

$$\sigma(a) = \frac{1}{1 + e^{-a}}.$$

El logit $a \in \mathbb{R}$ es el valor producido por el discriminador antes de aplicar la función sigmoide.

A partir de estas definiciones:

a. Demuestre que

$$\frac{\partial}{\partial a} \log(1 - \sigma(a)) = -\sigma(a),$$

mientras que

$$\frac{\partial}{\partial a}[-\log \sigma(a)] = -(1 - \sigma(a)).$$

b. Evalúe ambos gradientes cuando

$$D_\phi(G_\theta(z)) \rightarrow 0.$$

- Explique, utilizando la regla de la cadena, por qué la formulación **minimax** puede proporcionar un gradiente débil al generador al comienzo del entrenamiento.
- Determine si las pérdidas **minimax** y no saturante tienen el mismo punto óptimo.
- Explique por qué cambiar la pérdida modifica la dinámica del entrenamiento, aunque no cambie el equilibrio deseado de la GAN.

4. El discriminador D_ϕ , parametrizado por ϕ , produce una salida $D_\phi(x) \in (0, 1)$, que pretende aproximar la probabilidad condicional $P(Y = 1 | X = x)$. Por ello, se modela la variable Y , condicionada a $X = x$, mediante una distribución de Bernoulli:

$$Y \mid X = x \sim \text{Bernoulli}(D_\phi(x)).$$

Considere un conjunto de entrenamiento $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m$, donde x_i es la i -ésima muestra y $y_i \in \{0, 1\}$ indica su procedencia.

a. Construya la función de verosimilitud para $\mathcal{D}$, suponiendo que las observaciones son condicionalmente independientes.

- b. Aplique logaritmo a la verosimilitud y demuestre que minimizar la log-verosimilitud negativa promedio conduce a

$$\mathcal{L}_D = -\frac{1}{m} \sum_{i=1}^m \left[y_i \log D_\phi(x_i) + (1 - y_i) \log (1 - D_\phi(x_i)) \right].$$

- c. Demuestre que el mínimo esperado de esta expresión se alcanza cuando

$$D_\phi(x) = P(Y = 1 | X = x).$$

- d. Interprete el resultado en términos de calibración probabilística.

Preguntas prácticas

El siguiente conjunto de preguntas están basadas en el notebook titulado L09_GAN_Pytorch ,el cual se encuentra disponible en el GitHub del curso

5. Estudie las clases Generator y Discriminator del notebook y construya una tabla que muestre, para cada capa: dimensión de entrada; dimensión de salida; función de activación; propósito de la capa. Posteriormente, responda:
- ¿Qué representa el vector de dimensión 100 que recibe el generador?
 - ¿Por qué la salida del generador tiene 784 elementos?
 - ¿Por qué el discriminador produce un único valor?
 - ¿Cómo debe interpretarse probabilísticamente ese valor?
 - Compruebe las dimensiones utilizando un minibatch y mostrando las formas de los tensores intermedios.

6. Identifique en train_gan() las instrucciones que implementan las siguientes pérdidas:

$$\mathcal{L}_D = -\frac{1}{2} \left[\frac{1}{m} \sum_{i=1}^m \log D(x_i) + \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(z_i))) \right],$$

y

$$\mathcal{L}_G = -\frac{1}{m} \sum_{i=1}^m \log D(G(z_i)).$$

Para cada término:

- Indique qué línea del código lo calcula.
- Explique qué representan real_labels y fake_labels.
- iguales a uno.

- d. Determine qué parámetros deben actualizarse en cada fase.
 - e. Finalmente, escriba el algoritmo de entrenamiento en pseudocódigo.
7. Entrene la GAN totalmente conectada y la DCGAN bajo condiciones comparables. Luego analice: número de parámetros; tiempo por época; evolución de las pérdidas; calidad visual; diversidad de las imágenes; posibles indicios de colapso de modos.

Responda:

- a. ¿Qué ventajas aporta la estructura convolucional?
- b. ¿Qué información espacial pierde la GAN lineal cuando aplana la imagen?
- c. ¿Una pérdida más baja implica necesariamente mejores imágenes?
- d. ¿Cuál de los dos modelos representa mejor la distribución de MNIST? Justifique con evidencia.

La comparación debe incluir una figura elaborada con los mismos vectores latentes para ambos modelos.

8. Modifique el notebook para que, cada cierto número de épocas, por ejemplo, cada 10 épocas, se generen y almacenen 1000 imágenes utilizando siempre el mismo conjunto de vectores latentes. Para cada punto del entrenamiento:
- a. Compare los histogramas de intensidades de las imágenes reales y generadas.
 - b. Calcule y compare las siguientes estadísticas: media; desviación estándar; mínimo y máximo; proporción de píxeles cercanos al fondo; proporción de píxeles correspondientes al trazo de los dígitos.
 - c. Represente imágenes reales y generadas en un espacio bidimensional utilizando PCA. En una misma gráfica, use colores diferentes para identificar ambos conjuntos.
 - d. Analice cómo cambia la separación entre las distribuciones a medida que avanza el entrenamiento.
 - e. Proponga una medida cuantitativa para estimar la diferencia entre las distribuciones y gráfiquela en función de la época.
 - f. ¿La evidencia gráfica y estadística permite afirmar que la distribución generada se aproxima progresivamente a la distribución de MNIST? ¿Existen épocas en las que las pérdidas mejoran, pero la similitud entre las distribuciones no lo hace? Justifique su respuesta.