Lecture 09
Deep Learning

Ph. D. Juan David Martínez Vargas
Ph. D. Raul Andrés Castañeda

Escuela de Ciencias Aplicadas e Ingeniería

Vigilada Mineducación

Agenda

- GradCam
- Autoencoders
- Convolutional Autoencoders

Grad-Cam

GAP: En lugar de usar capas densas tradicionales al final, se aplica un promedio global a cada mapa de características final.

Entrada: Imagen (niño con un perro).

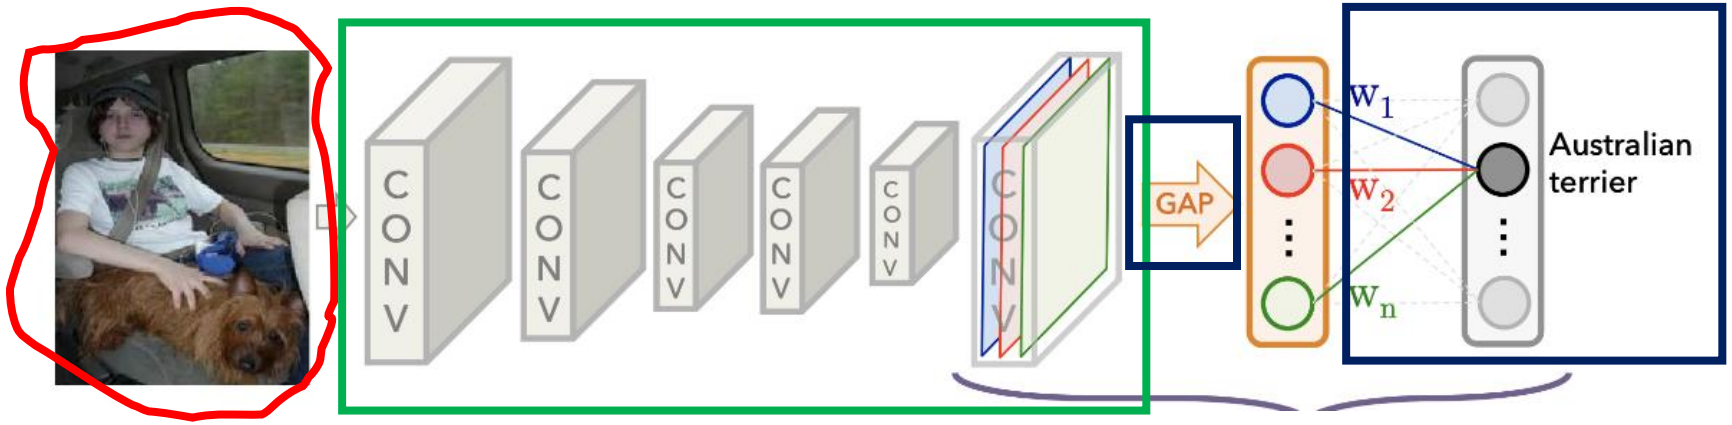

Capas convoucionales: Extracción de características (bordes simples, formas complejas)

Capa de salida: Cada conexión tiene un peso asociado para una clase específica ("Australian terrier")

Grad-Cam

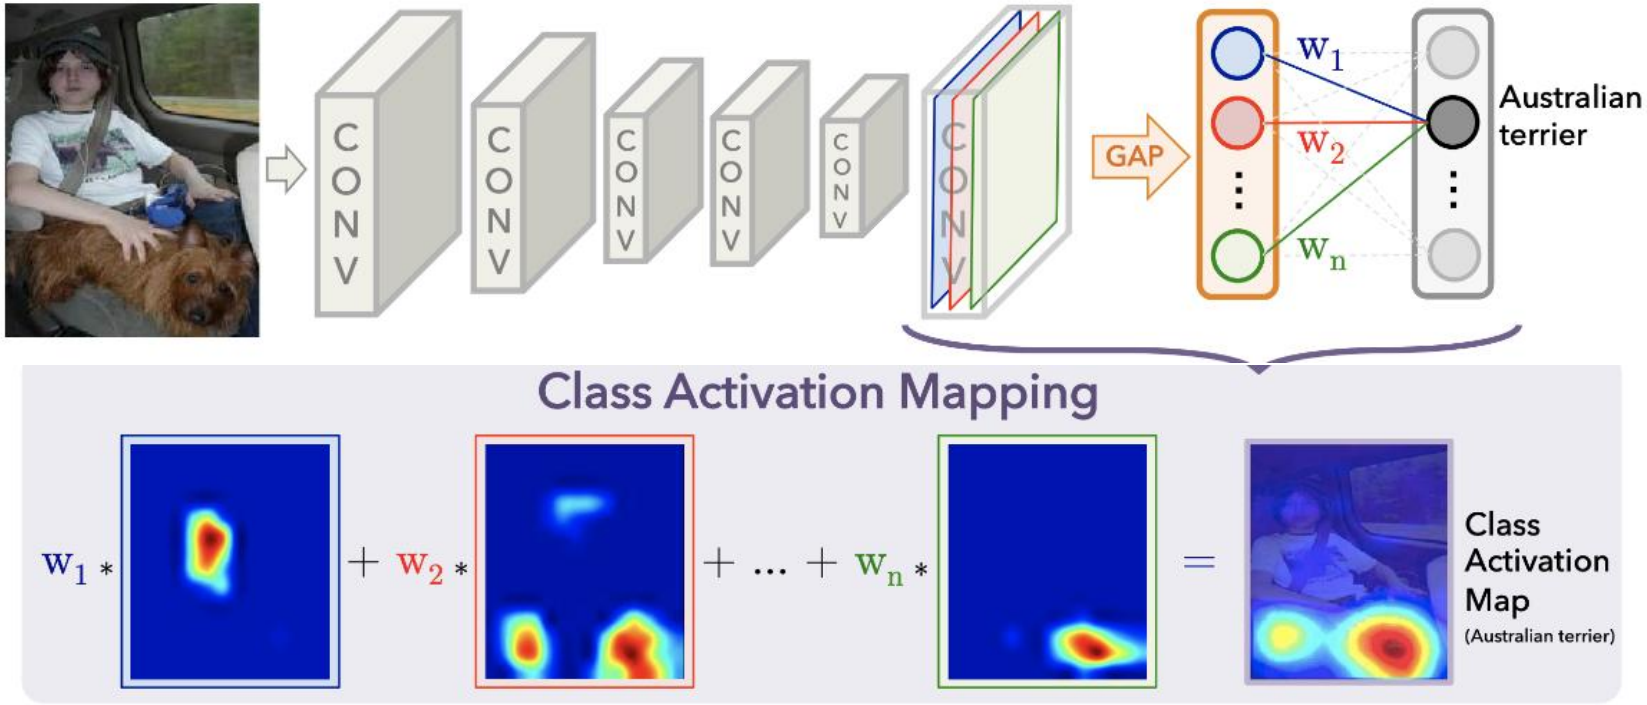

Al combinar todos los mapas ponderados, se obtiene un **mapa de calor** superpuesto a la imagen original. Los valores máximos se concentra sobre el perro, confirmando que la red identificó correctamente al "Australian terrier" basándose en los pixeles del animal y no en el niño o el fondo.

Grad-Cam

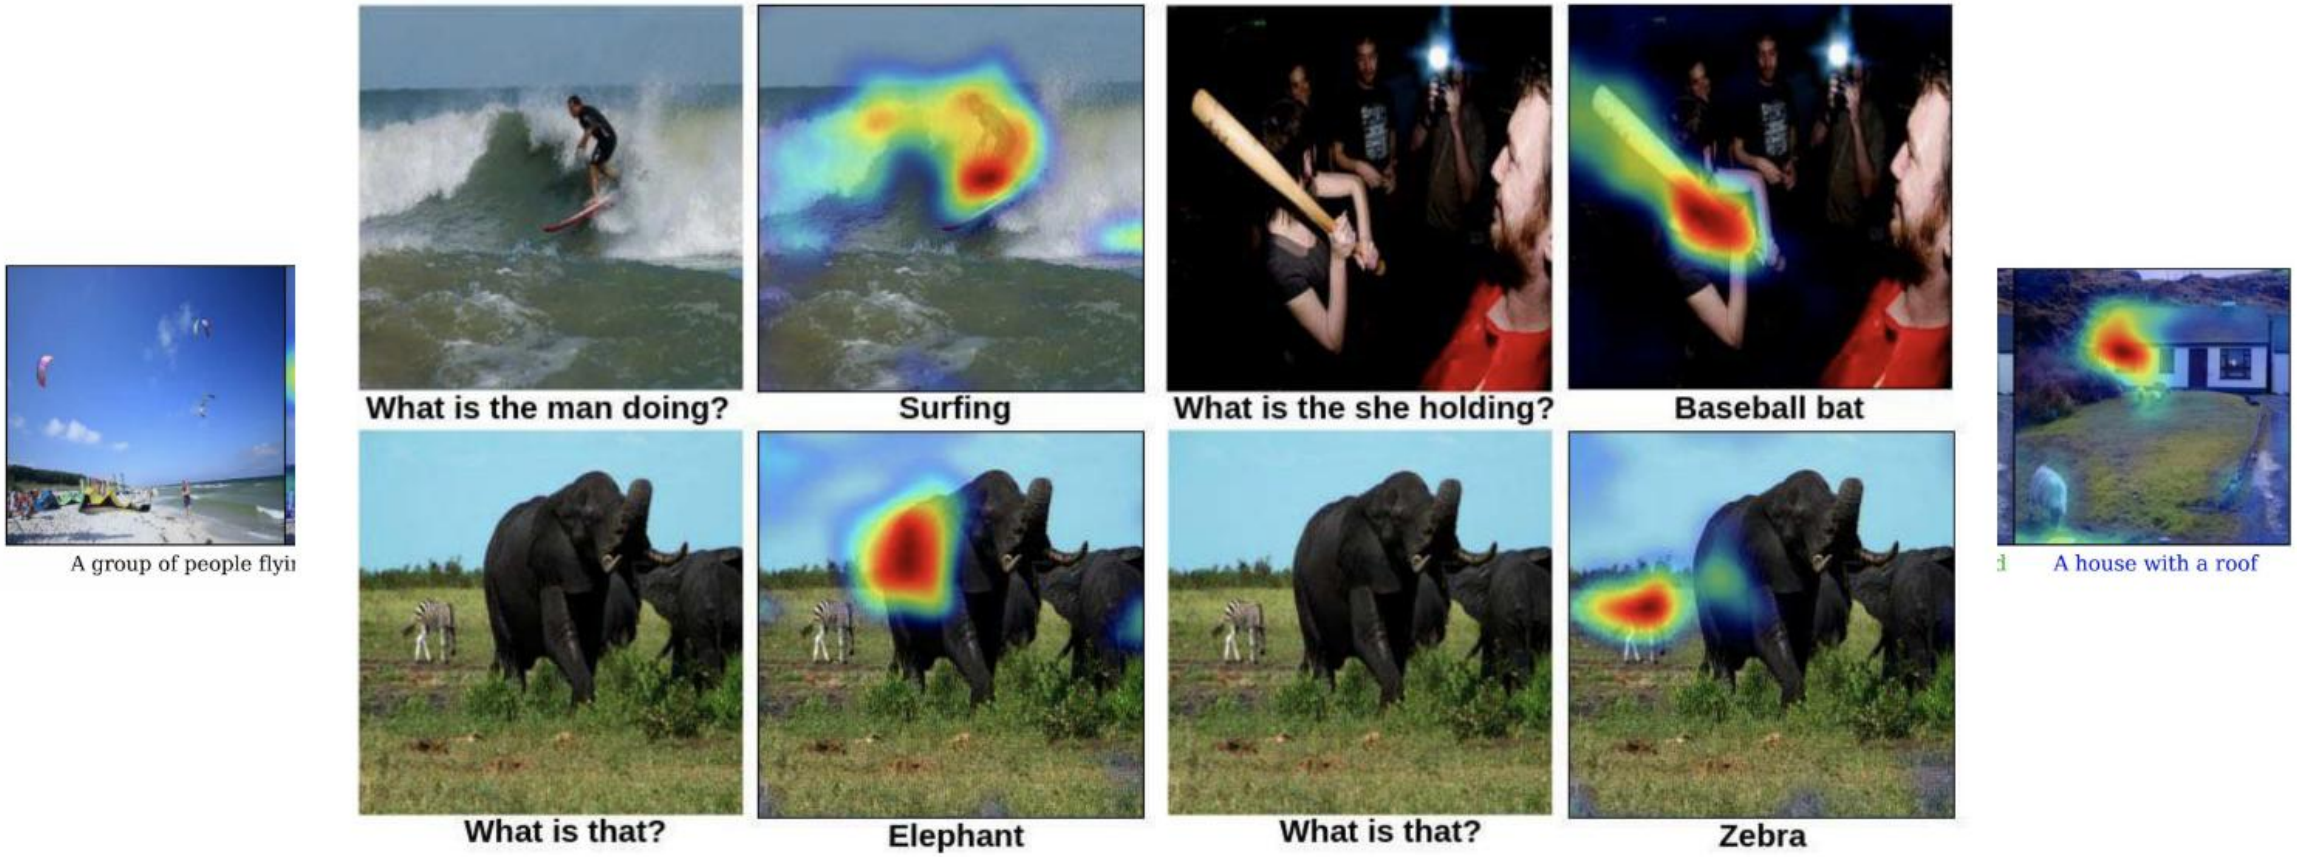

(b) Visualizing ResNet based Hierarchical co-attention VQA model from [29]

AutoEncoders

Un perceptrón multicapa en forma de reloj de arena

- Reducción de dimensionalidad
- Codificadores automáticos completamente conectados
- Codificadores automáticos convolucionales
- Otros tipos de codificadores automáticos

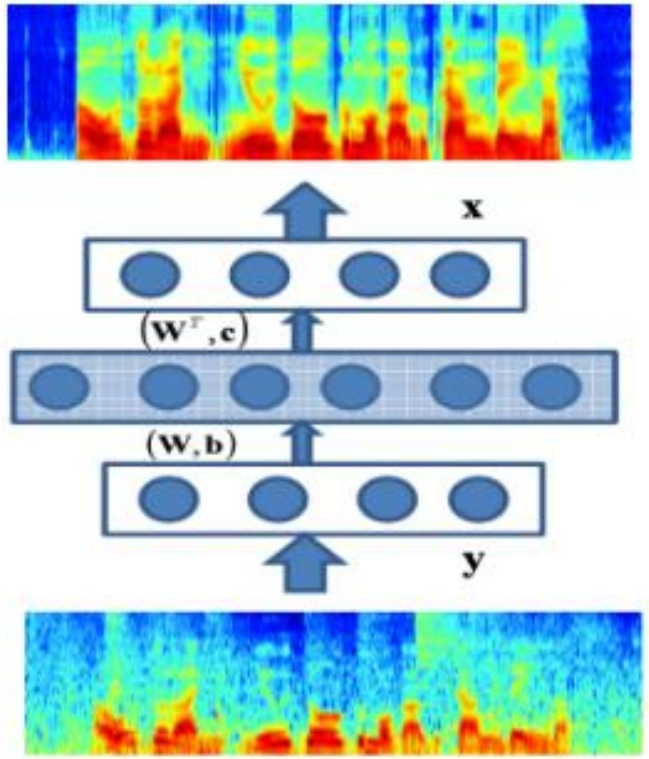

Figure 1: Training neural autoencoder with noisy-clean speech pairs.

Lu, X., Tsao, Y., Matsuda, S., & Hori, C. (2013, August). Speech enhancement based on deep denoising autoencoder. In Interspeech (pp. 436-440).

AutoEncoders

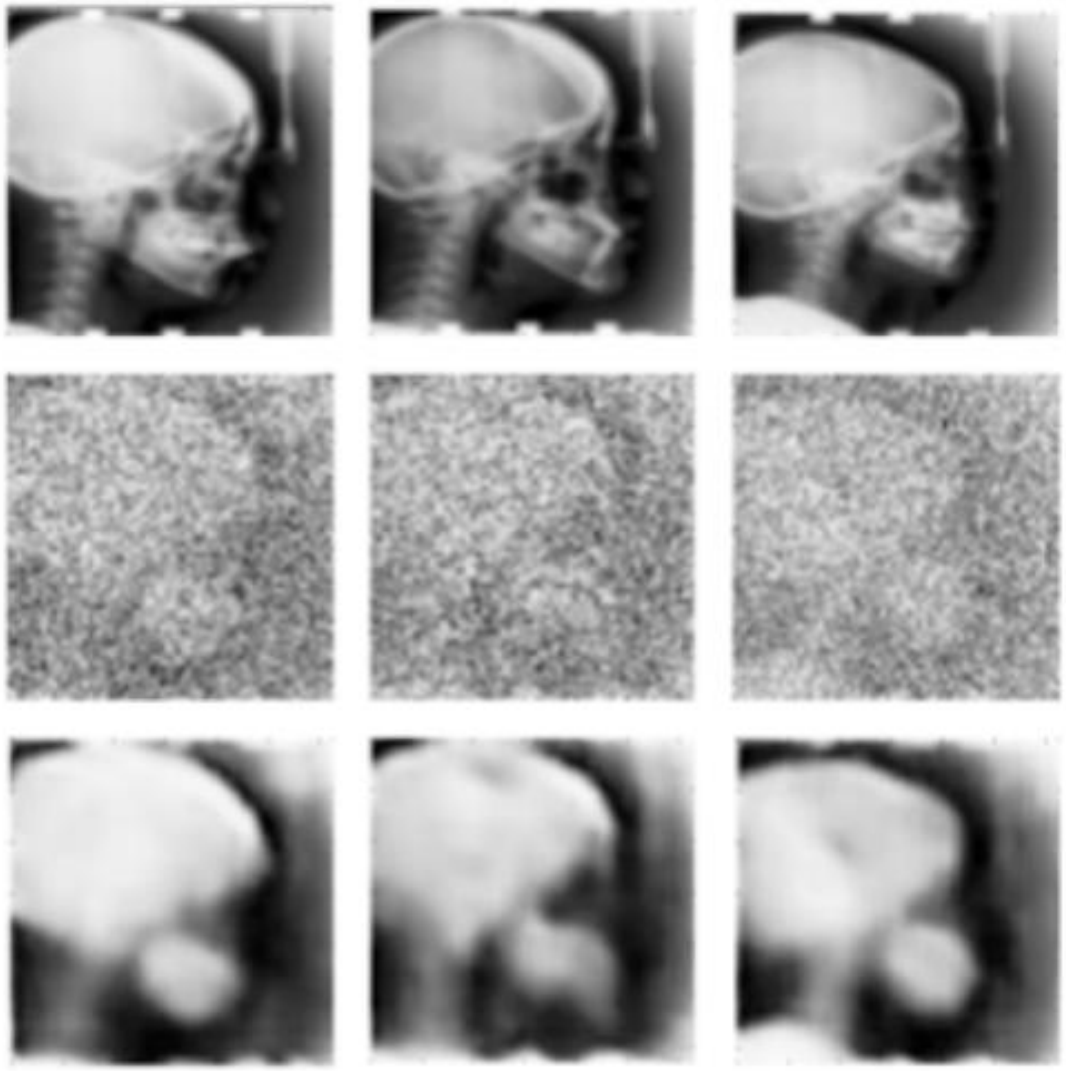

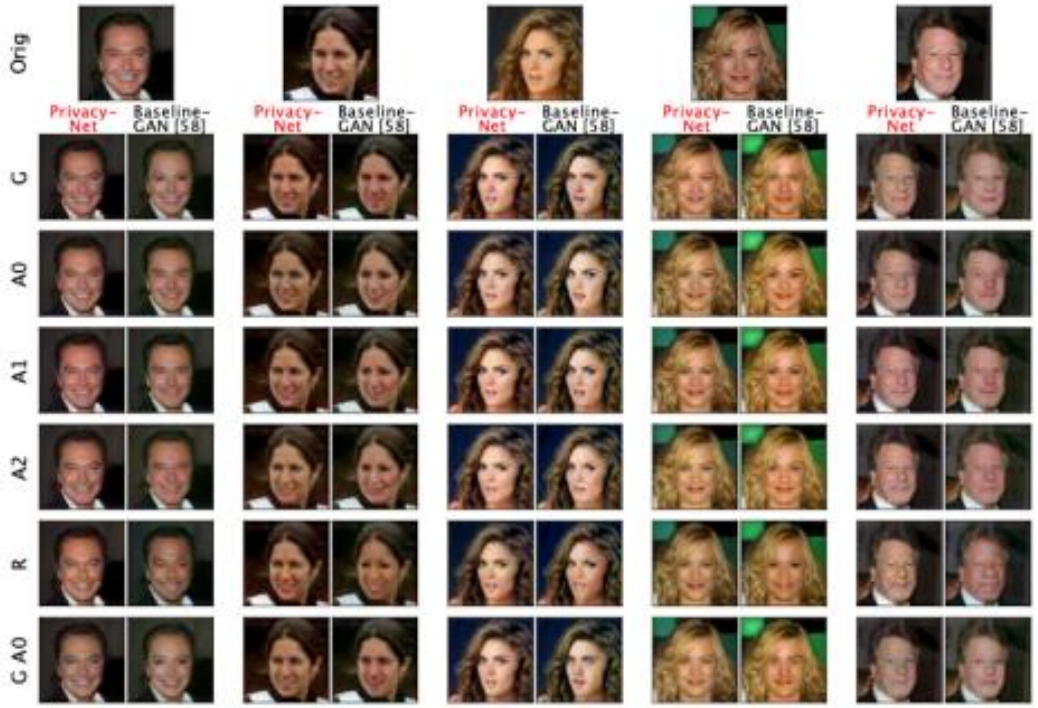

"About half (52%) of U.S. adults said they decided recently not to use a product or service because they were worried about how much personal information would be collected about them."

https://www.pewresearch.org/fact-tank/2020/04/14/half-of-americans-have-decided-not-to-use-a-product-or-service-because-of-privacy-concerns/

Gondara, L. (2016, December). Medical image denoising using convolutional denoising autoencoders. In 2016 IEEE 16th International Conference on Data Mining Workshops (ICDMW) (pp. 241-246). IEEE.

AutoEncoders Reducción de dimensionalidad

Aprendizaje no supervisado

Trabajar con conjuntos de datos sin considerar la variable de destino

Algunas aplicaciones y objetivos:

- Encontrar estructuras ocultas en los datos
- Compresión de datos
- Agrupación
- Recuperar objetos similares
- Análisis exploratorio de datos
- Generando nuevos ejemplos

Análisis de componentes principales (PCA por sus siglas en inglés)

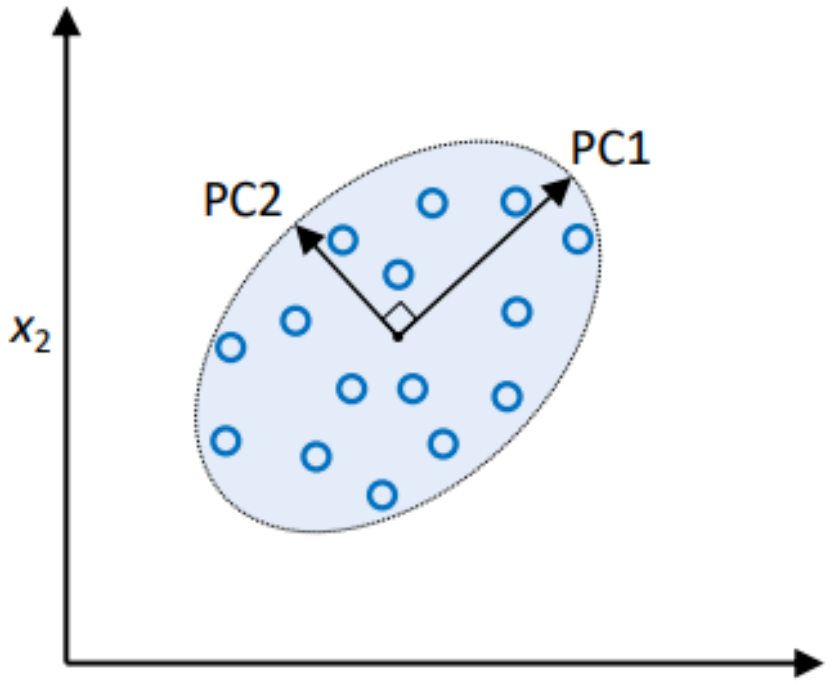

AutoEncoders Reducción de dimensionalidad

Análisis de componentes principales (PCA por sus siglas en inglés)

Transformar características en direcciones de máxima variación.

Encontrar direcciones de mayor varianza

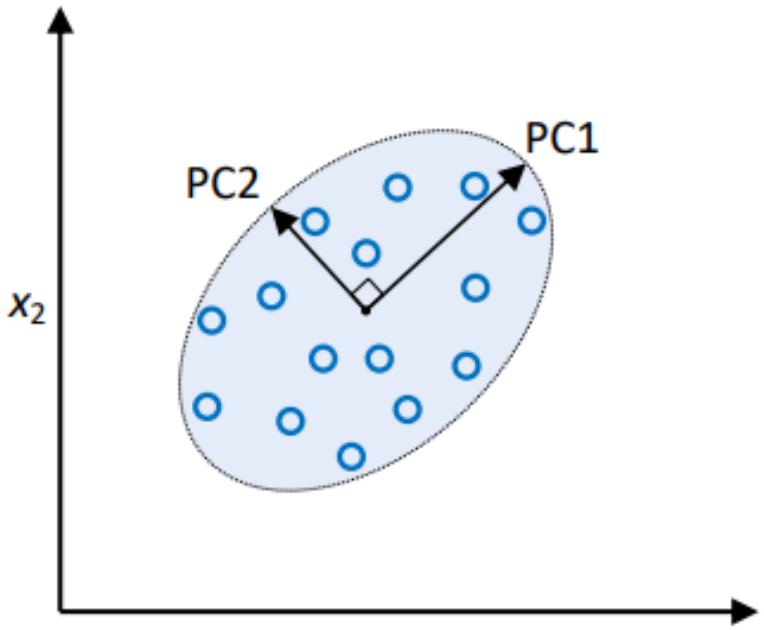

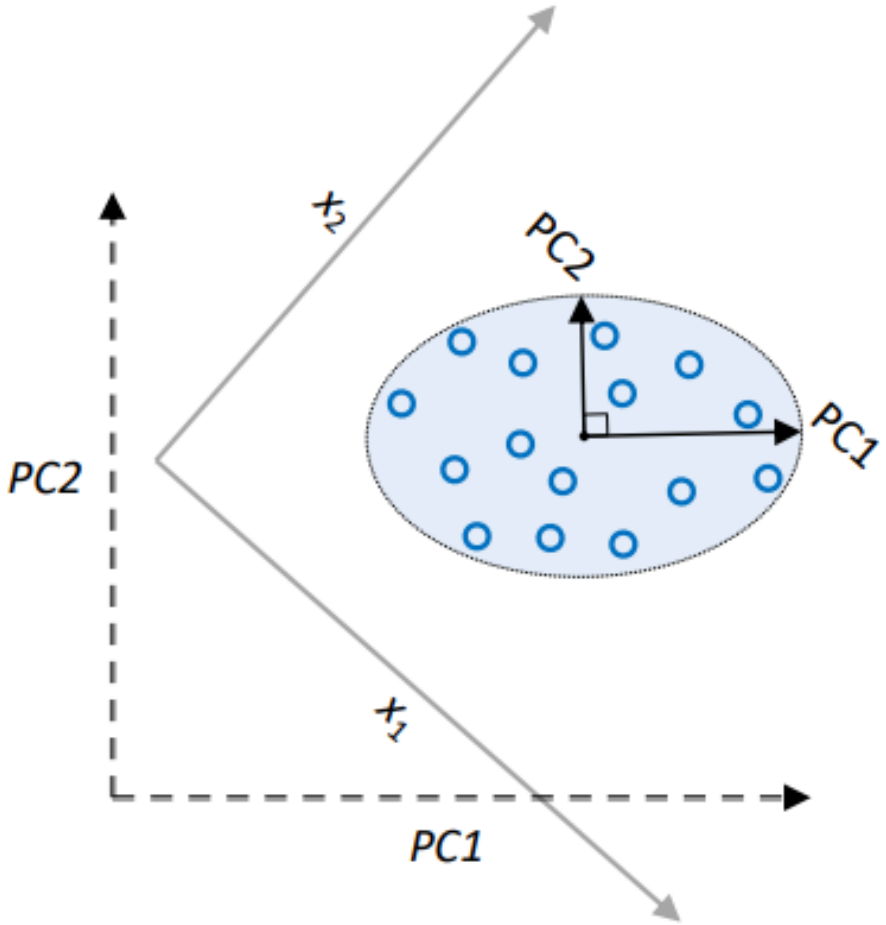

UNIVERSIDAD EAFIT

AutoEncoders Reducción de dimensionalidad

Análisis de componentes principales
(PCA por sus siglas en inglés)

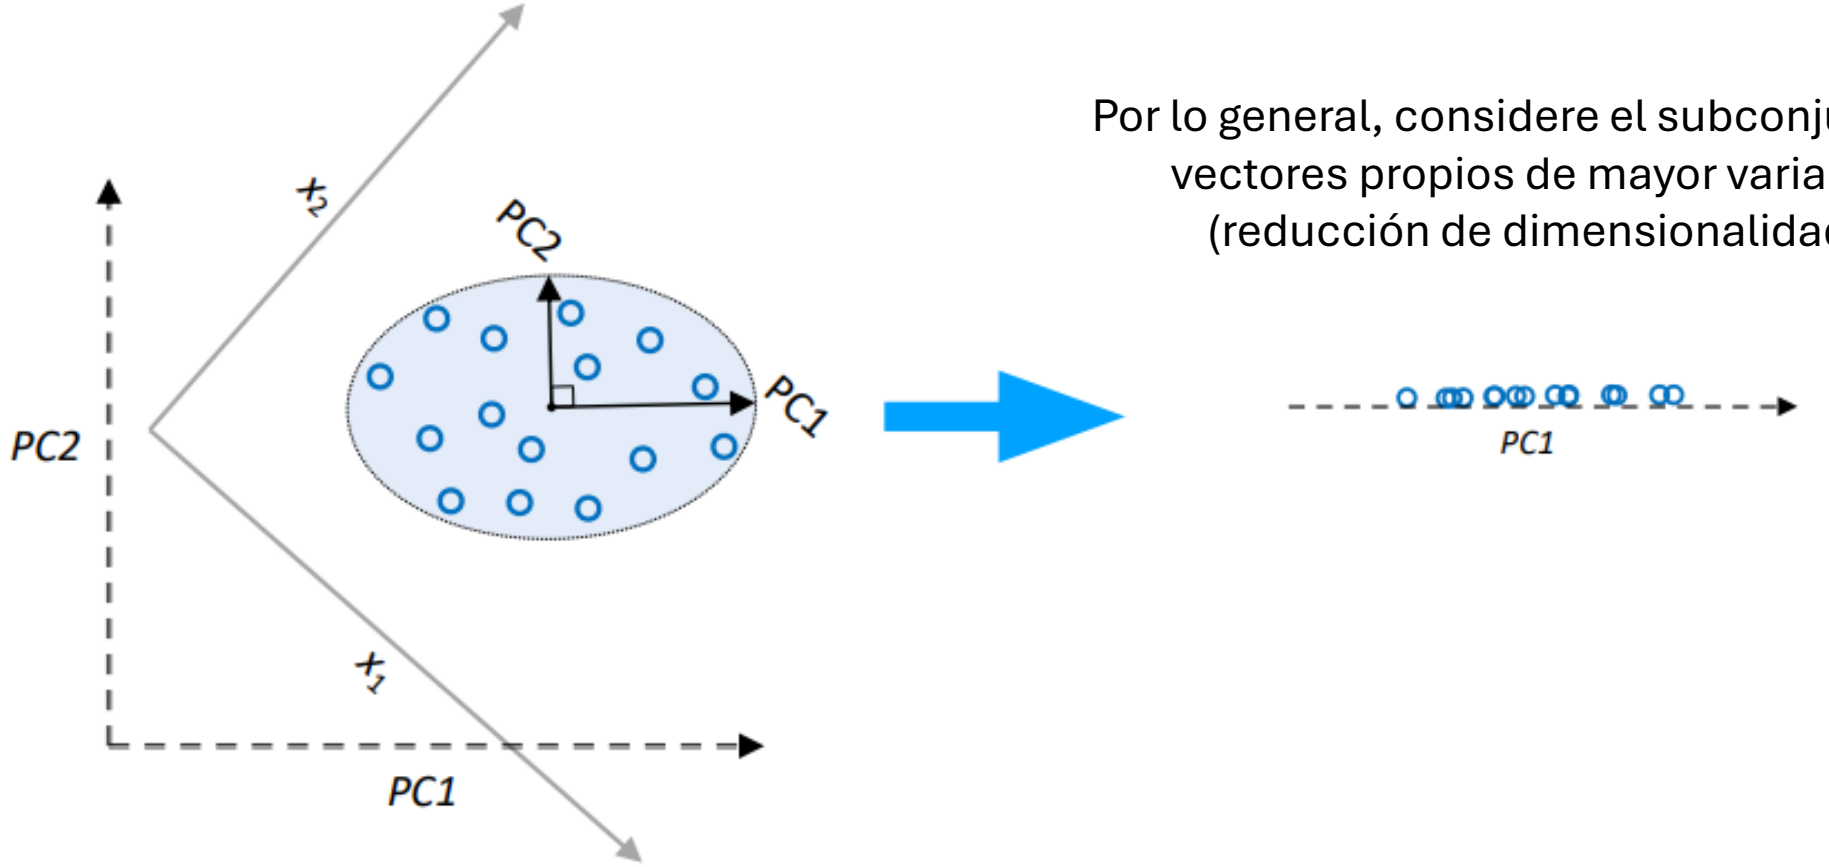

Por lo general, considere el subconjunto de vectores propios de mayor varianza (reducción de dimensionalidad)

UNIVERSIDAD EAFIT

AutoEncoders completamente conectados

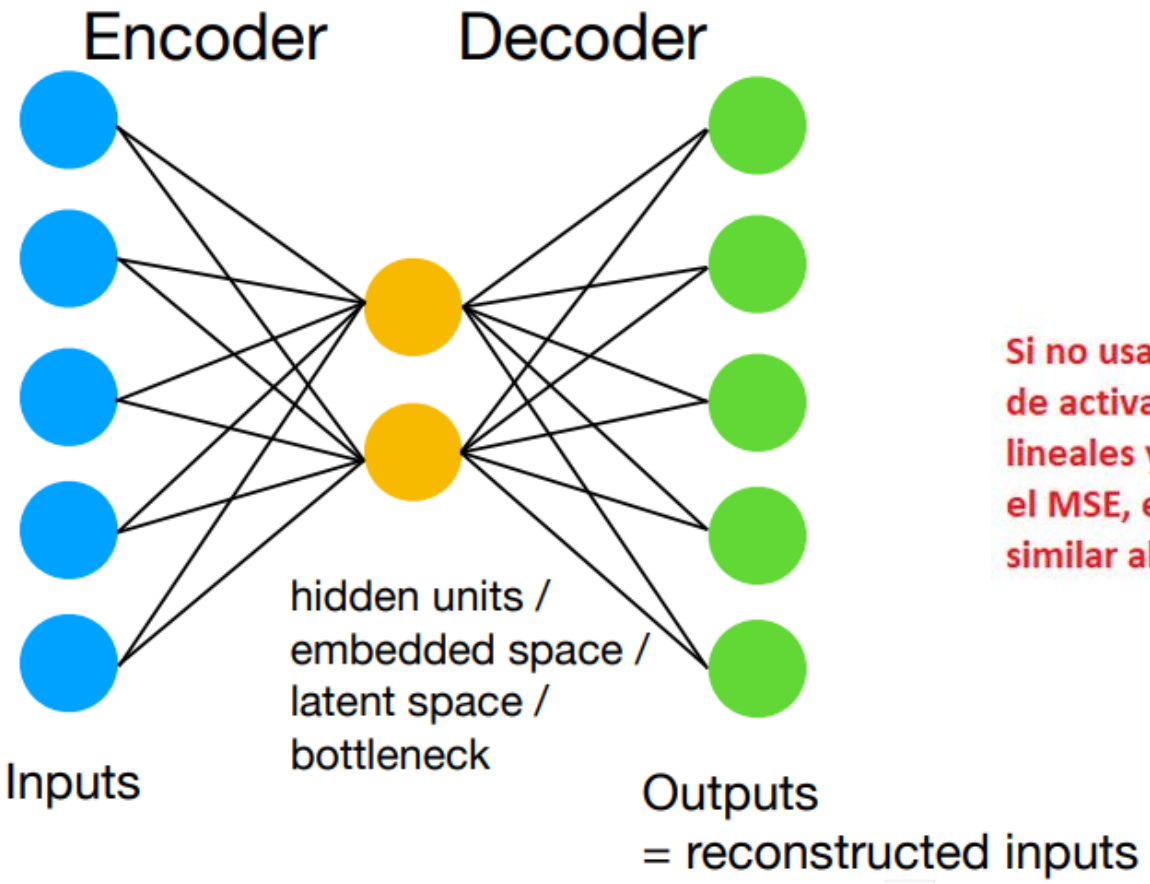

Si no usamos funciones de activación no lineales y minimizamos el MSE, esto es muy similar al PCA

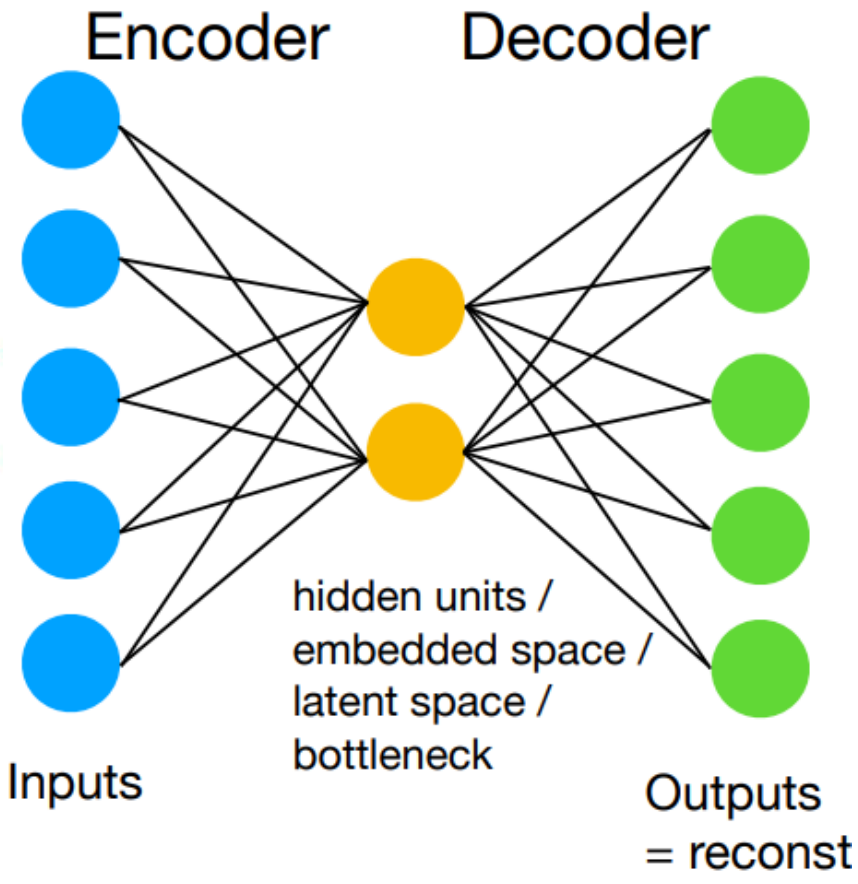

$$\mathcal{L}(\mathbf{x}, \mathbf{x}') = ||\mathbf{x} - \mathbf{x}'||_2^2 = \sum_i (x_i - x_i')^2$$

AutoEncoders completamente conectados

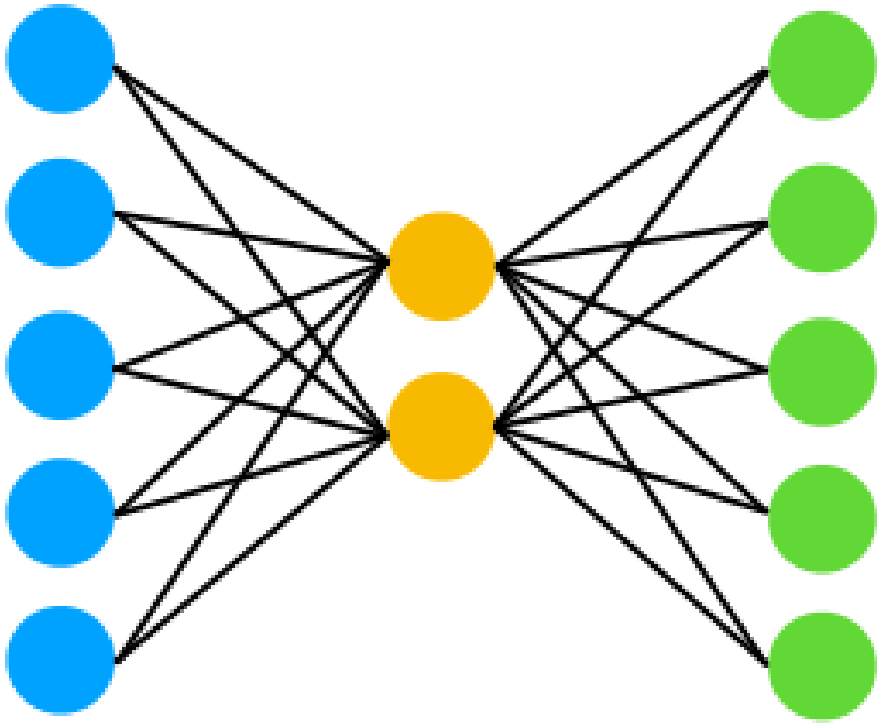

Pregunta:

Si podemos lograr lo mismo con PCA, que es esencialmente un tipo de factorización matricial que es más eficiente que Backprop + SGD, ¿por qué molestarse con los codificadores automáticos?

$$\mathcal{L}(\mathbf{x}, \mathbf{x}') = ||\mathbf{x} - \mathbf{x}'||_2^2 = \sum_i (x_i - x_i')^2$$

AutoEncoders completamente conectados

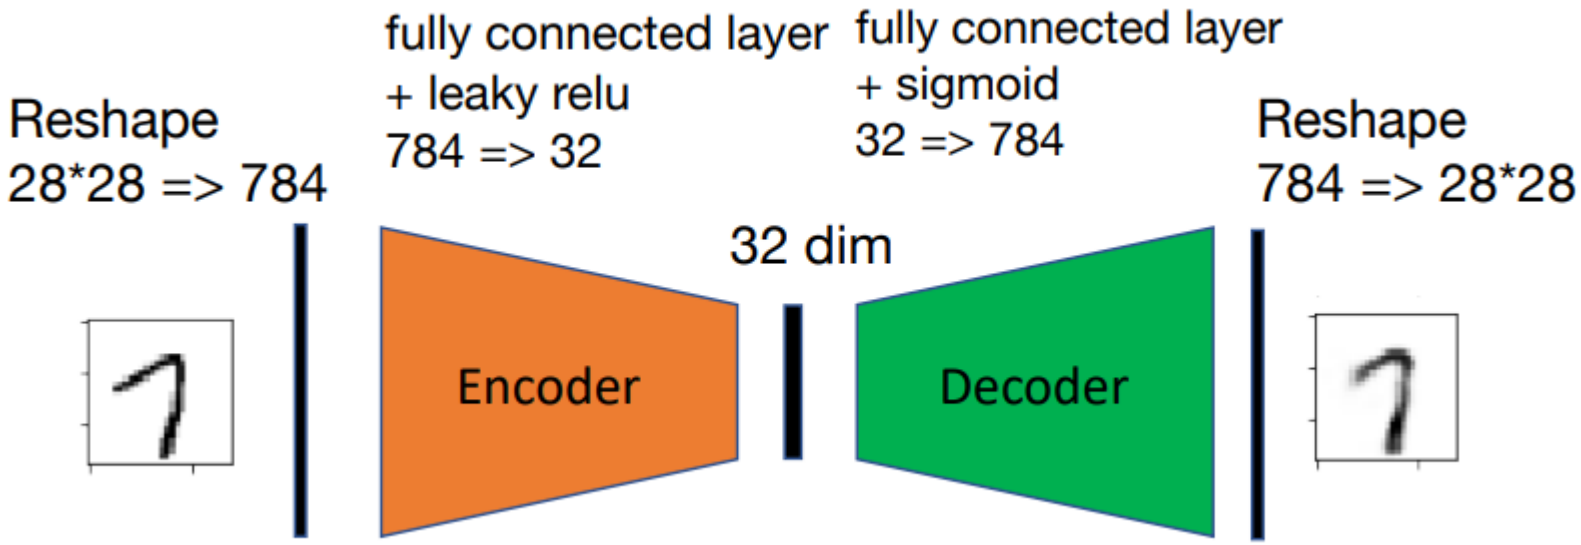

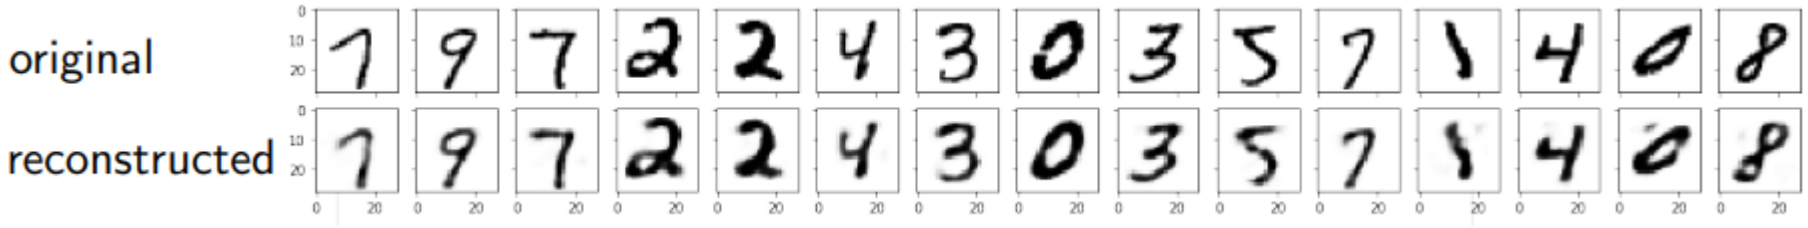

AutoEncoders Convolucionales

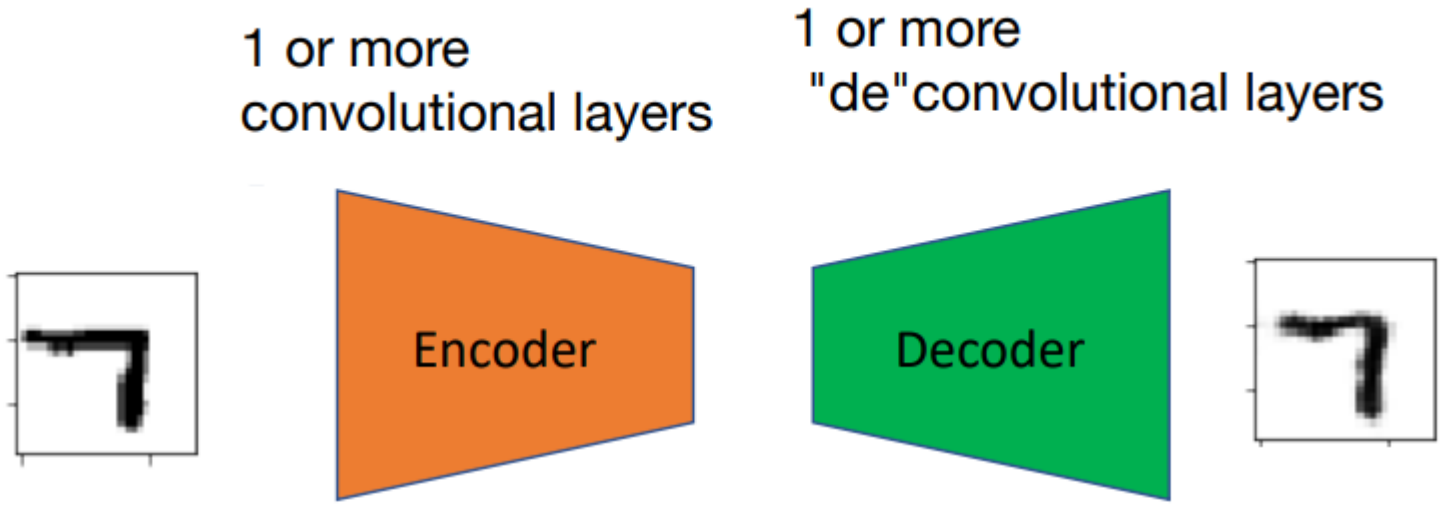

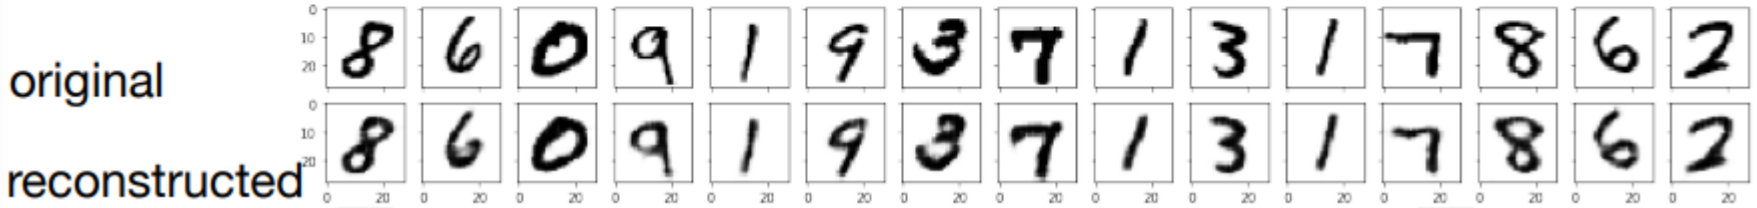

AutoEncoders Convolucionales

Convolución Transpuesta

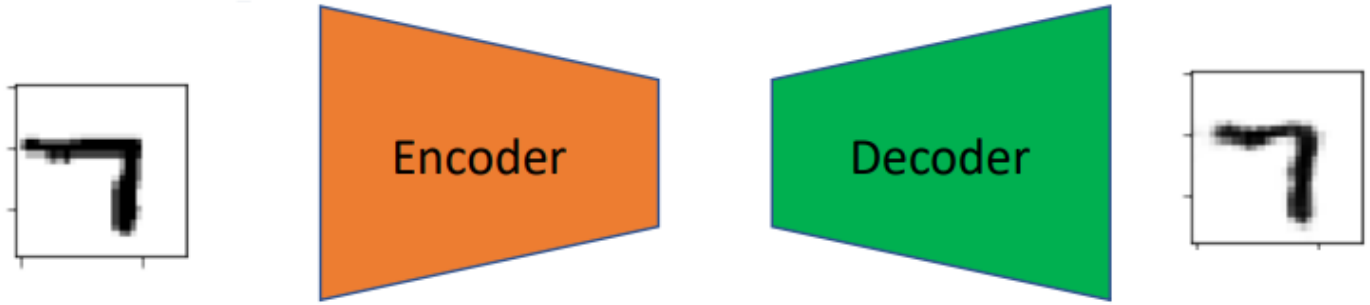

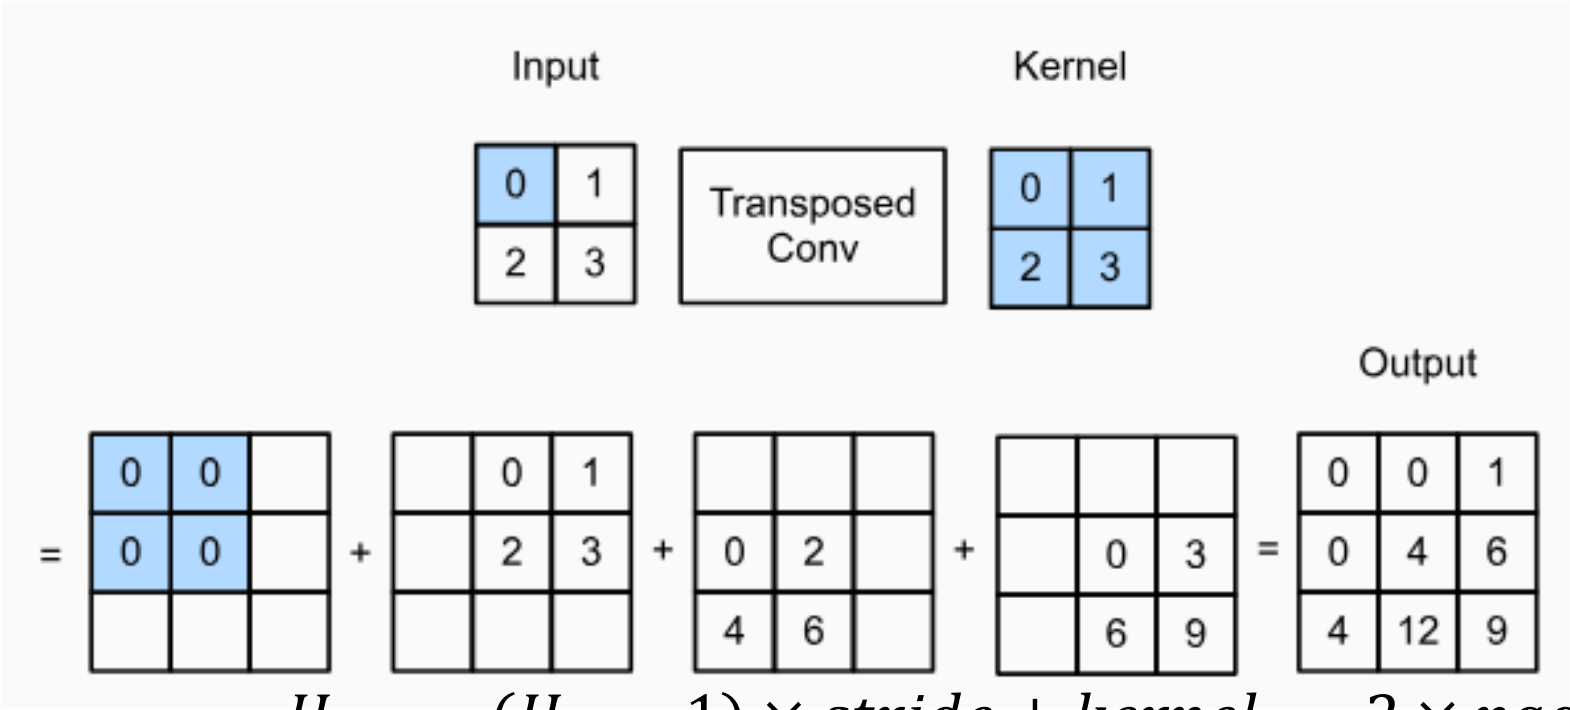

convoluciones transpuestas generan o amplían las dimensiones de los datos, como generar imágenes de mayor resolución a partir de imágenes de menor resolución

$$H_{out} = (H_{in} - 1) \times stride + kernel \; - \; 2 \times padding$$

AutoEncoders Convolucionales

Convolución regular

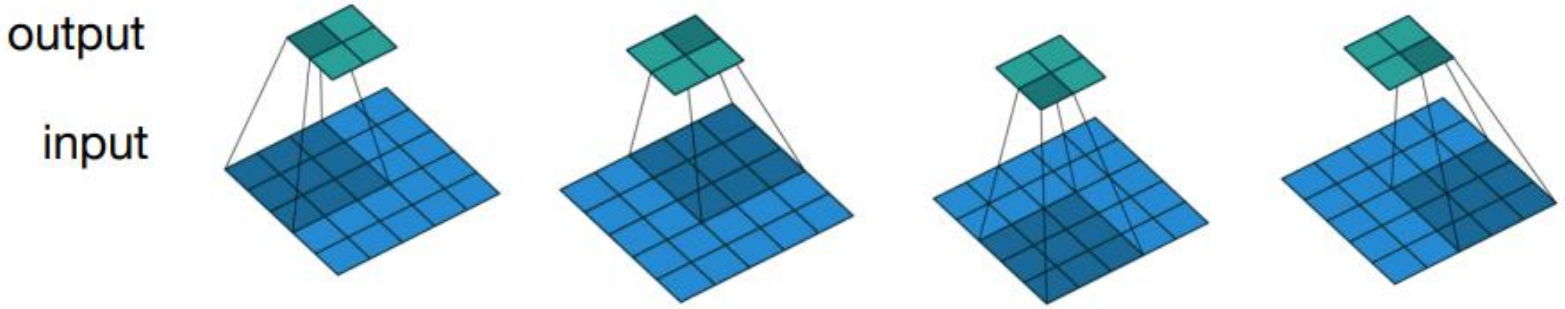

Dumoulin, Vincent, and Francesco Visin. "A guide to convolution arithmetic for deep learning." arXiv preprint arXiv:1603.07285 (2016). https://arxiv.org/abs/1603.07285

Convolución transpuesta (paso = 2):

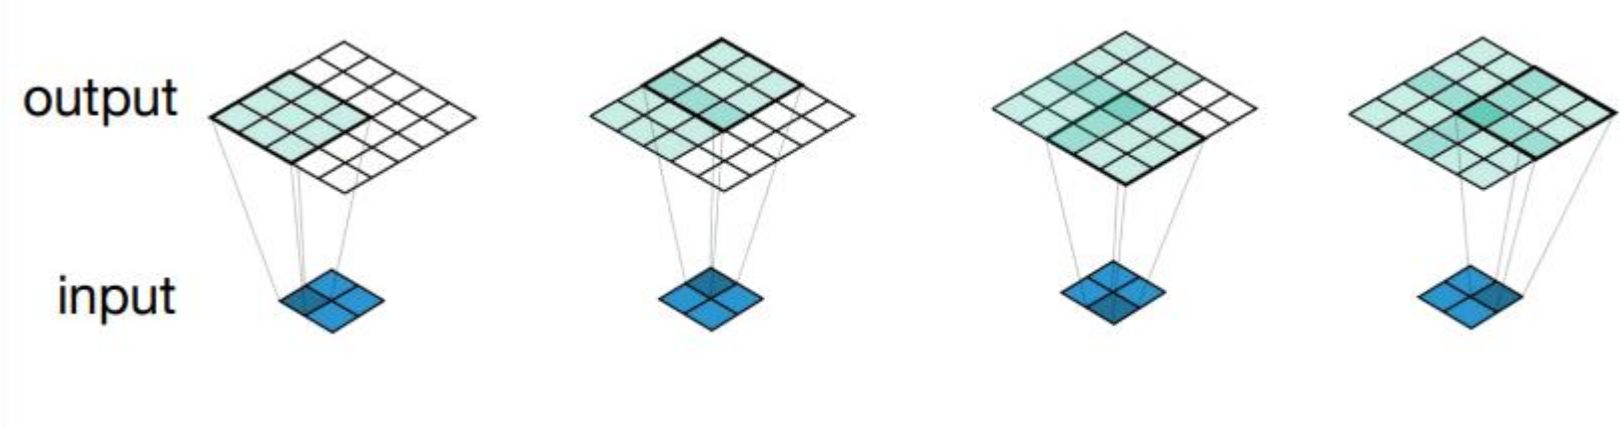

A Conv2DTranspose with 3x3 kernel and stride of 2x2 applied to a 2x2 input to give a 5x5 output. (https://medium.com/apache-mxnet/transposed-convolutions-explained-with-ms-excel-52d13030c7e8)

AutoEncoders Convolucionales

Convolución Transpuesta kernel 3 x3, paso 2

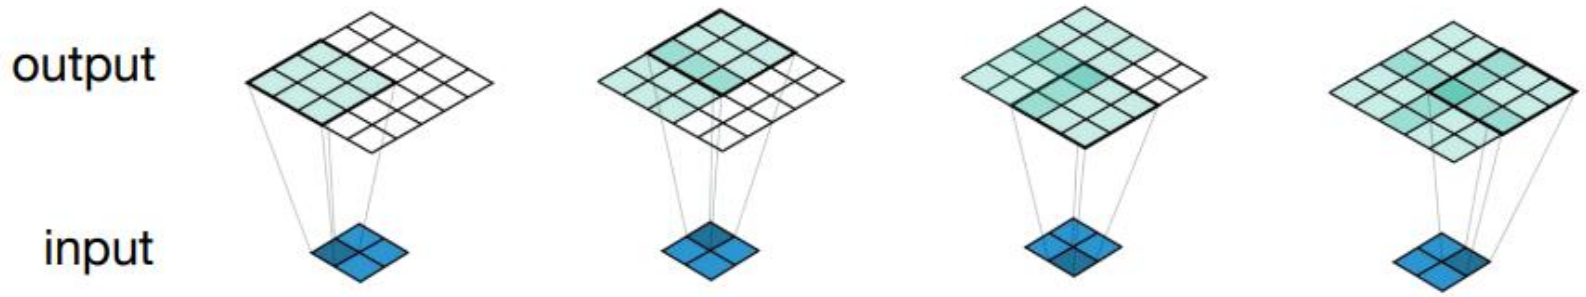

A Conv2DTranspose with 3x3 kernel and stride of 2x2 applied to a 2x2 input to give a 5x5 output.
(https://medium.com/apache-mxnet/transposed-convolutions-explained-with-ms-excel-52d13030c7e8)

Convolución Transpuesta (emulada con convolución directa)

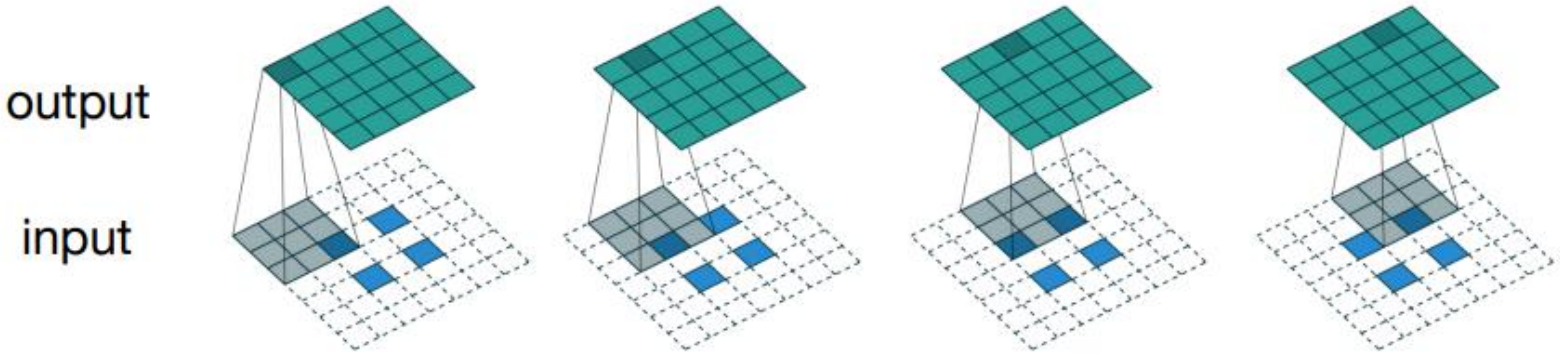

Dumoulin, Vincent, and Francesco Visin. "A guide to convolution arithmetic for deep learning." arXiv preprint arXiv:1603.07285 (2016). https://arxiv.org/abs/1603.07285

AutoEncoders Convolucionales

Convolución regular: (paso = 1):

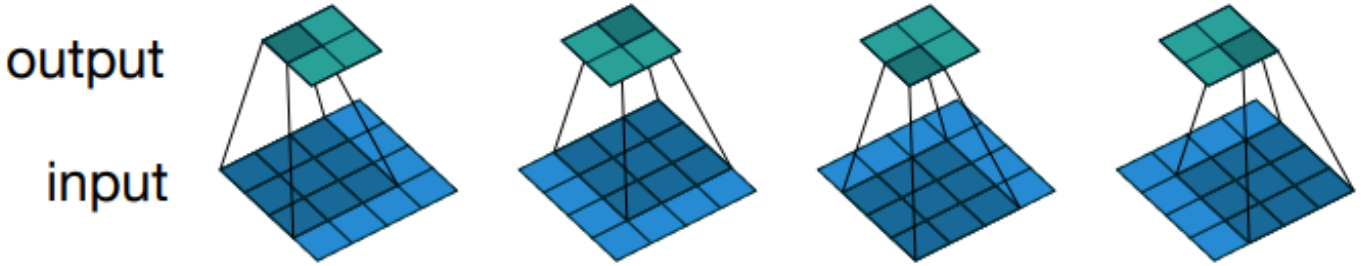

Convolución transpuesta (emulada con convolución directa): (paso = 1)

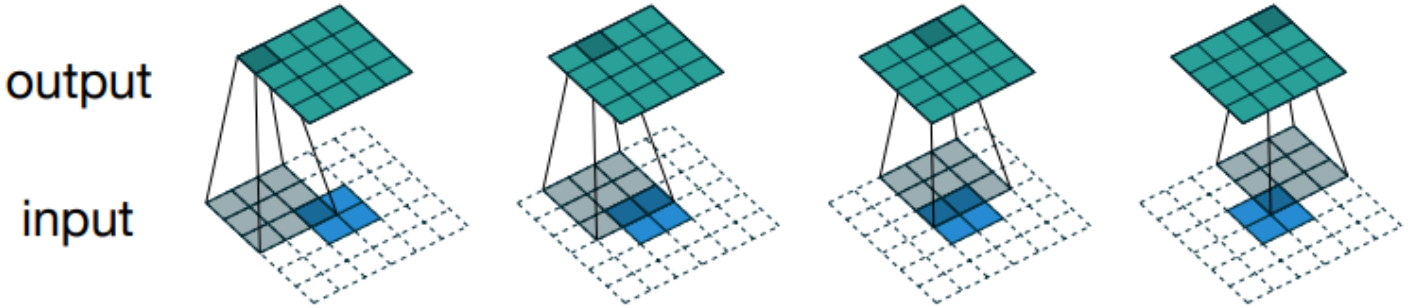

Dumoulin, Vincent, and Francesco Visin. "A guide to convolution arithmetic for deep learning." arXiv preprint arXiv:1603.07285 (2016).
https://arxiv.org/abs/1603.07285

AutoEncoders Convolucionales

Deconvolution and Checkerboard Artifacts

AUGUSTUS ODENA Google Brain
VINCENT DUMOULIN Université de Montréal
CHRIS OLAH Google Brain
Oct. 17 2016
Citation: Odena, et al., 2016

Un buen artículo interactivo que destaca los peligros de la convolución transpuesta.

https://distill.pub/2016/deconv-checkerboard/

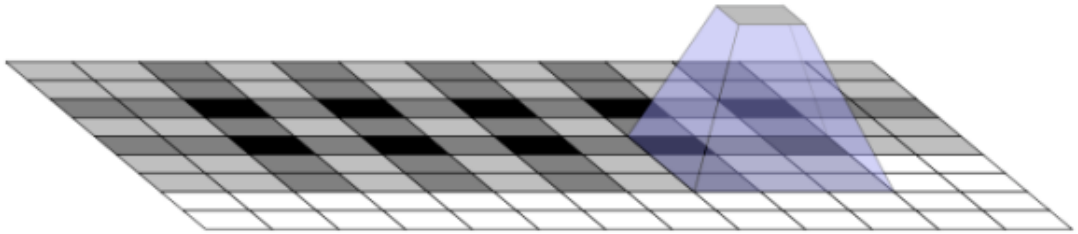

En resumen, recomienda reemplazar la convolución transpuesta por muestreo ascendente (interpolación) seguido de convolución regular

Agregue capas de dropout para obligar a las redes a aprender características redundantes

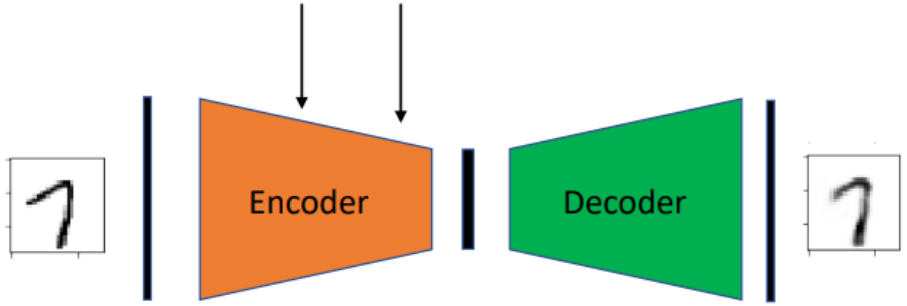

https://wiki.cloudfactory.com/docs/mp-wiki/key-principles-of-computer-vision/upsampling-and-downsampling-techniques-in-machine-learning

AutoEncoders Reducción de ruido

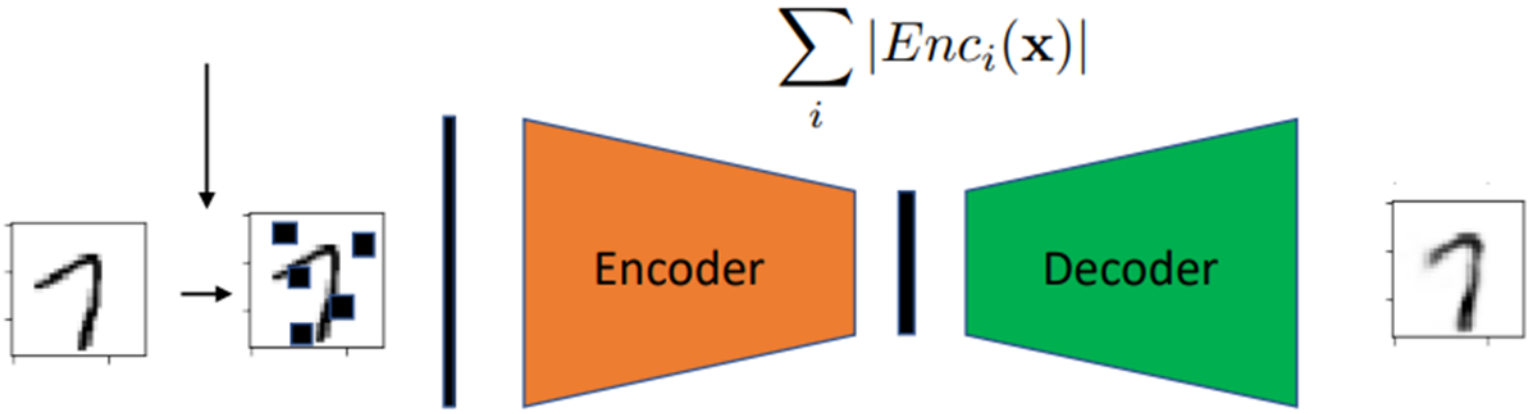

$$\mathcal{L} = ||\mathbf{x} - Dec(Enc(\mathbf{x}))||_2^2 + \sum_i |Enc_i(\mathbf{x})|$$

Agregue una penalización L1 a la pérdida para aprender representaciones de características dispersas

Vincent, P., Larochelle, H., Bengio, Y., & Manzagol, P. A. (2008, July). Extracting and composing robust features with denoising autoencoders. In Proceedings of the 25th International Conference on Machine Learning (pp. 1096-1103). ACM. http://www.cs.toronto.edu/~larocheh/publications/icml-2008-denoising-autoencoders.pdf

AutoEncoders Reducción de ruido

$$L^{[i]} = -\mathbb{E}_{z\sim q_w(z|x^{[i]})}\left[\log p_w\left(x^{[i]}|z\right)\right] + \mathbf{KL}\left(q_w\left(z|x^{[i]}\right)\|p(z)\right)$$

Expected neg. log likelihood term; wrt to encoder distribution
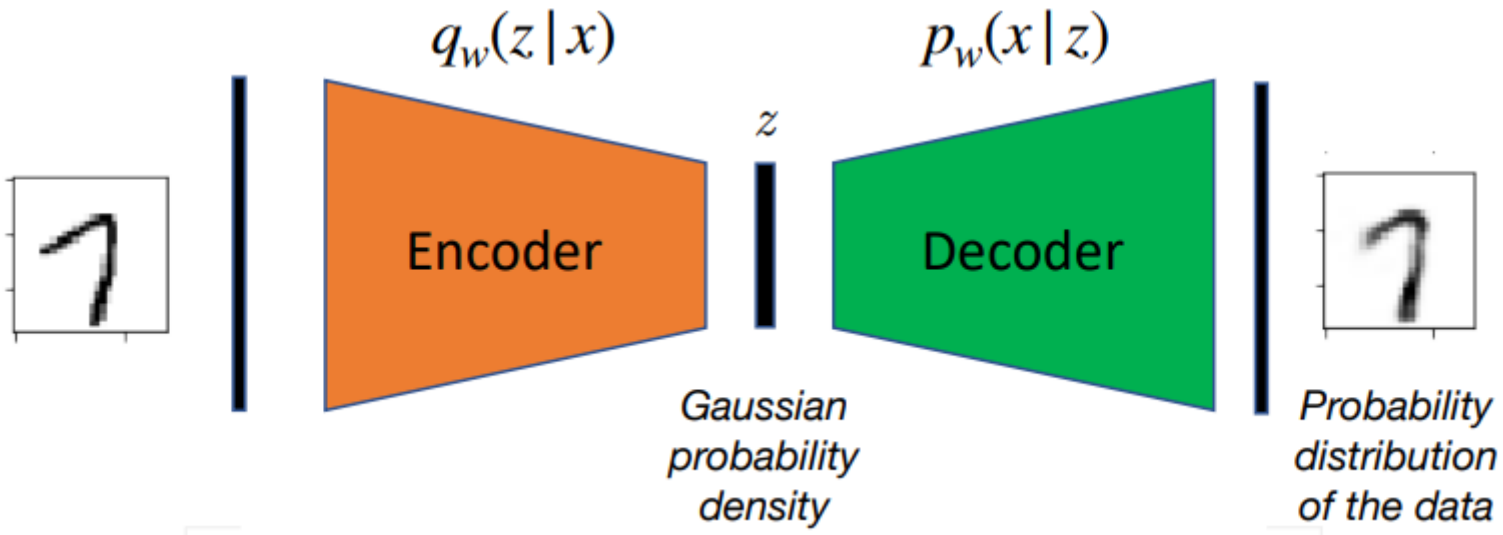
Kullback-Leibler divergence term where $p(z) = \mathcal{N}\left(\mu = 0, \sigma^2 = 1\right)$