

Ph. D. Juan David Martínez Vargas
Ph. D. Raul Andrés Castañeda

Escuela de Ciencias Aplicadas e Ingeniería

Lecture 12

RNN and LSTM

II

Agenda

- **RNN Limitaciones**
- **LSTM**



RNN - Limitaciones

¿Qué pasa si el orden de los datos importa?

Es importante que la red se retroalimente a sí misma

$$h^{<t>} = f(\underbrace{w_{hx}x^{<t>}}_{\text{Presente}} + \underbrace{w_{hh}h^{<t-1>}}_{\text{Pasado}} + b_h)$$

$$y^{<t>} = \sigma(w_{yh}h^{<t>} + b_y)$$



Este peso se multiplica muchas veces en el tiempo

RNN - Limitaciones

Las RNN fallan en secuencias largas esto motiva a otras arquitecturas como **LSTM**.

“El libro que compré ayer en la feria... [muchas palabras] ... era caro”

Información al inicio
que se necesita
recordar


Información necesaria para
predecir

$$y^{<t>} = \sigma(w_{yh}h^{<t>} + b_y) \quad h^{<t>} = f(w_{hx}x^{<t>} + w_{hh}h^{<t-1>} + b_h)$$

$$w_{hh} \Rightarrow \frac{\partial L}{\partial w_{hh}} = \frac{\partial L^{<t>}}{\partial y^{<t>}} \frac{\partial y^{<t>}}{\partial h^{<t>}} \left[\sum_{k=1}^t \frac{\partial h^{<t>}}{\partial h^{<k>}} \frac{\partial h^{<k>}}{\partial w_{hh}} \right]$$

Vanishing Gradient

Este peso se multiplica
muchas veces. **Causa del
problema**



RNN - Limitaciones

Backpropagation a través del tiempo [BPTT]

$$\frac{\partial L}{\partial w_{hh}} = \frac{\partial L^{<t>}}{\partial y^{<t>}} \frac{\partial y^{<t>}}{\partial h^{<t>}} \left[\sum_{k=1}^t \frac{\partial h^{<t>}}{\partial h^{<k>}} \frac{\partial h^{<k>}}{\partial w_{hh}} \right]$$

$$\frac{\partial h^{<t>}}{\partial h^{<k>}} = \prod_{j=k}^{t-1} \frac{\partial h^{<j+1>}}{\partial h^{<j>}}$$

Es un producto de muchas derivadas a lo largo del tiempo

$$\frac{\partial h^{<t>}}{\partial h^{<k>}} = \frac{\partial h^{<t>}}{\partial h^{<t-1>}} \frac{\partial h^{<t-1>}}{\partial h^{<t-2>}} \dots$$




Si las derivadas $\frac{\partial h^{(j+1)}}{\partial h^{(j)}}$ tienen valores menores que 1 en magnitud,

el producto se hace cada vez más pequeño → Vanishing Gradient

Cuando retropropagamos hacia atrás en el tiempo:


Vanishing Gradient

- Los gradientes se hacen cada vez más pequeños.
- La red deja de aprender dependencias largas.



Exploding Gradient

- Los gradientes crecen sin control.
- Entrenamiento inestable.



Consecuencia: la RNN estándar tiene dificultad para capturar **relaciones de largo plazo** en secuencias largas.


RNN - Limitaciones

$$h^{<1>} = \tanh(w_{hh}h^{<0>} + w_{hx}x^{<1>})$$

$$h^{<2>} = \tanh(w_{hh}h^{<1>} + w_{hx}x^{<2>}) \quad \xrightarrow{\quad} \quad h^{<2>} = \tanh(w_{hh}[\tanh(w_{hh}h^{<0>} + w_{hx}x^{<1>})] + w_{hx}x^{<2>})$$


$$h^{<3>} = \tanh(w_{hh}h^{<2>} + w_{hx}x^{<3>})$$

$$h^{<3>} = \tanh(w_{hh}(\tanh(w_{hh}[\tanh(w_{hh}h^{<0>} + w_{hx}x^{<1>})] + w_{hx}x^{<2>})) + w_{hx}x^{<3>})$$



LSTM (Long Short-Term Memory)

- Es un tipo de red neuronal artificial que permite comprender y recordar patrones en los datos durante largos periodos.
- A diferencia de las RNN, que olvidan rápidamente, LSTM puede retener información importante durante muchos pasos.
- Esto la hace perfecta para tareas donde el orden de los datos es crucial, como la comprensión del habla o la predicción de precios de acciones.



Sebastian Raschka, Vahid Mirjalili. Python Machine Learning. 3rd Edition. Birmingham, UK: Packt Publishing, 2019

LSTM componentes

Componentes clave de un LSTM

➤ Memory Cell:

- Almacena información a lo largo del tiempo.
- Permite que la red recuerde detalles importantes durante muchos pasos.

➤ Input Gate:


- Decide qué nueva información se almacena en la celda.
- Regula el flujo de datos que entran al sistema.

➤ Forget Gate:

- Decide qué información se descarta de la celda.
- Permite eliminar datos irrelevantes o innecesarios.

➤ Output Gate:

- Decide qué información se utiliza como salida.
- Controla qué parte de la memoria se expone al resto de la red.



LSTM

$c^{<t-1>}$
 $c^{<t>}$

Cell state

$h^{<t-1>}$
 $h^{<t>}$

hidden state

$W=(w_{fx}, w_{fh}, w_{ix}, w_{ih}, w_{gx}, w_{gh}, w_{ox}, w_{oh})$ **Pesos**

$b=(b_f, b_i, b_g, b_h)$ **Sesgos**

$$f = \sigma[w_{fx}x^{(t)} + w_{fh}h^{(t-1)} + b_f]$$

$$i = \sigma[w_{ix}x^{(t)} + w_{ih}h^{(t-1)} + b_i]$$

$$g = \tanh[w_{gx}x^{(t)} + w_{gh}h^{(t-1)} + b_g]$$

$$o = \sigma[w_{ox}x^{(t)} + w_{oh}h^{(t-1)} + b_o]$$

$$c^{(t)} = c^{(t-1)} \cdot f + i \cdot g$$



$$z^{(i)} = \sum_{j=1}^T \alpha_{ij} x^{(j)}$$

Reinterpretación de Token, teniendo en cuenta todo el contenido de la frase.

LSTM (Long Short-Term Memory)

- Step i → Matriz de correlación.
- Step ii → Attention scores.
- Step iii → Cálculo de z.